MAKALAH PROYEK SAINS DATA

Chatbot Analitik UMKM Berbasis AI dan Machine Learning

Akuisisi dan Kesiapterapan Data

Disusun untuk memenuhi tugas mata kuliah Proyek Sains Data

Dosen Pengampu

Assoc. Prof. Dr. Irawan Afrianto, S.T., M.T.

Disusun oleh

Kelompok 3

Muhammad Rizki Sisaya

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK DAN ILMU KOMPUTER

UNIVERSITAS KOMPUTER INDONESIA (UNIKOM)

2026

ABSTRAK

Projek Chatbot Analitik UMKM bertujuan membangun sistem analitik berbasis kecerdasan buatan untuk membantu pemilik toko nonteknis mencatat transaksi dan memahami performa usaha melalui percakapan. Projek ini didukung dataset publik E-commerce Sales & Customer Analytics dari Kaggle yang diunduh pada 10 Oktober 2026 dan terdiri atas lima berkas CSV dengan 46 kolom, 138.116 baris transaksi, 24.911 pelanggan unik, dan 1.175 produk unik, mencakup periode 2021 hingga 2025. Penelitian ini menjawab pertanyaan: data apa yang digunakan, bagaimana akuisisinya, bagaimana kualitasnya, dan apakah data tersebut layak untuk membangun lima modul machine learning yang direncanakan. Tahapan penelitian meliputi akuisisi dan verifikasi berkas, profiling otomatis, pemeriksaan kualitas enam dimensi, dan penyusunan matriks kesesuaian kolom terhadap model. Hasil menunjukkan seluruh berkas terbaca bersih (0 karakter rusak), 0 duplikat baris penuh, serta tidak ada duplikat pada kunci order_id; namun 17,78% transaksi tidak memiliki rating dan ulasan karena berstatus Cancelled, Pending, atau Returned. Konsistensi agregat terbukti: jumlah net_sales sebesar $177.134.263,74 persis sama dengan dataset_statistics.csv, demikian pula profit $76.146.395,76 dan average order value $1.282,50. Skor rating rata-rata 3,68 dan terkonsentrasi pada rentang 3,3–3,9; sentimen ulasan didominasi positif (68,76%) dengan kelas negatif sangat timpang (0,7%). Analisis kesiapterapan menunjukkan forecasting, RFM+K-Means, market basket, churn (jendela 365 hari sebelum 31 Desember 2025; 8.156 pelanggan tergolong churn), dan anomaly detection layak dijalankan; kolom customer_lifetime_value, customer_order_count, dan is_repeat_customer tidak dipakai sebagai fitur karena berisiko data leakage. Kesimpulannya, data layak dipakai untuk training model global dengan catatan penanganan imbalance dan pemahaman bahwa dataset mencerminkan pola transaksi sintetis multi-negara, bukan transaksi tenant nyata.

Kata Kunci: akuisisi data, kualitas data, kesiapterapan, machine learning, UMKM, e-commerce

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa karena makalah dengan judul “Chatbot Analitik UMKM Berbasis AI dan Machine Learning: Akuisisi dan Kesiapterapan Data” dapat diselesaikan. Makalah ini disusun untuk memenuhi tugas mata kuliah Proyek Sains Data dan mendokumentasikan proses pengumpulan, profiling, serta penilaian kelayakan data yang dipakai projek.

Penulis mengucapkan terima kasih kepada dosen pengampu Assoc. Prof. Dr. Irawan Afrianto, S.T., M.T. atas arahan selama pengerjaan. Penulis juga menyadari makalah ini masih memiliki kekurangan; masukan dan kritik yang membangun sangat diharapkan.

Bandung, 6 November 2026

Tim Penyusun

DAFTAR ISI

ABSTRAK

KATA PENGANTAR

DAFTAR ISI

DAFTAR GAMBAR

DAFTAR TABEL

BAB I. PENDAHULUAN

- 1.1 Latar Belakang
- 1.2 Rumusan Masalah
- 1.3 Tujuan
- 1.4 Manfaat
- 1.5 Ruang Lingkup

BAB II. DESKRIPSI DATA

- 2.1 Sumber Data
- 2.2 Jenis Data
- 2.3 Dataset yang Dihasilkan dan Relasinya
- 2.4 Kamus Data

BAB III. AKUISISI DATA

- 3.1 Perangkat yang Digunakan
- 3.2 Tahapan Akuisisi
- 3.3 Kendala dan Penanganan
- 3.4 Etika dan Keamanan Data
- 3.5 Reprodusibilitas

BAB IV. PROFIL DAN KUALITAS DATA

- 4.1 Ringkasan Statistik
- 4.2 Sebaran Transaksi dan Negara
- 4.3 Karakteristik Status Order dan Produk
- 4.4 Distribusi Rating dan Sentimen

4.5 Distribusi Temporal
4.6 Kelengkapan Atribut
4.7 Pemeriksaan Kualitas Data
BAB V. KESIAPTERAPAN DATA PADA PROJEK
5.1 Arsitektur Sistem (Rencana)
5.2 Pemetaan Data ke Tahap Pemodelan
5.3–5.7 Kesiapan per Modul
5.8 Mitigasi Keterbatasan Data
5.9 Rencana Tahap Selanjutnya
BAB VI. PENUTUP
6.1 Kesimpulan
6.2 Saran
DAFTAR PUSTAKA
LAMPIRAN A. Statistik Deskriptif Per Kolom
LAMPIRAN B. Perintah Reprodusibilitas

DAFTAR GAMBAR

Gambar 3.1 Corong akuisisi data

Gambar 4.1 Sebaran transaksi per negara

Gambar 4.2 Komposisi status order

Gambar 4.3 Sebaran kategori produk

Gambar 4.4 Distribusi rating pelanggan

Gambar 4.5 Komposisi sentimen ulasan

Gambar 4.6 Jumlah transaksi per bulan (2021–2025)

Gambar 4.7 Keterisian atribut pasca-transaksi dan marketing

Gambar 5.1 Arsitektur data–model–aplikasi (rencana)

DAFTAR TABEL

Tabel 2.1 Sumber data dan cara akses

Tabel 2.2 Jenis data dan contoh atribut

Tabel 2.3 Dataset yang dihasilkan dan relasi

Tabel 2.4 Kamus data ecommerce_sales_customer_analytics_150k.csv

Tabel 2.5 Kamus data order_items.csv

Tabel 2.6 Kamus data customer_master.csv

Tabel 2.7 Kamus data product_catalog.csv

Tabel 2.8 Kamus data dataset_statistics.csv

Tabel 3.1 Perangkat yang digunakan dalam akuisisi

Tabel 3.2 Kendala akuisisi dan penanganannya

Tabel 4.1 Ringkasan statistik utama

Tabel 4.2 Matriks kualitas data enam dimensi

Tabel 5.1 Pemetaan data ke tahap pemodelan

Tabel 5.2 Mitigasi keterbatasan data

BAB I. PENDAHULUAN

1.1 Latar Belakang

Pemilik toko dan pelaku UMKM di Indonesia menghadapi penumpukan data transaksi tanpa alat analisis yang mudah dipakai. Catatan penjualan, pelanggan, dan produk tersimpan rapi di aplikasi, tetapi pemilik tidak punya cara cepat untuk menjawab pertanyaan sehari-hari: produk apa yang paling laku, pelanggan mana yang berhenti membeli, dan berapa perkiraan penjualan bulan depan. Solusi yang tersedia umumnya berupa dashboard kompleks yang menuntut literasi analitik tinggi.

Projek Chatbot Analitik UMKM menjawab masalah itu lewat antarmuka percakapan. Pemilik toko dapat mencatat penjualan atau bertanya performa usaha dengan bahasa sehari-hari; sistem lalu mengusulkan tindakan terstruktur (dengan konfirmasi) atau menjawab berdasarkan data nyata, bukan karangan. Di balik antarmuka itu dibutuhkan lima modul machine learning: forecasting penjualan, segmentasi RFM + K-Means, market basket analysis, prediksi churn, dan anomaly detection.

Sebelum model dilatih, data harus dipastikan layak. Data yang dipakai untuk training adalah dataset publik E-commerce Sales & Customer Analytics dari Kaggle (pengunggah: datascikhan; URL pada Daftar Pustaka), diunduh manual pada 10 Oktober 2026, terdiri atas lima berkas CSV. Data tenant nyata belum tersedia pada tahap ini; dataset publik dipakai sebagai bahan training model global, sedangkan data tenant dikelola terpisah di MySQL dan dipakai saat inferensi per toko.

Pemeriksaan awal memperlihatkan gambaran yang kontras: kualitas struktural sangat baik (0 karakter rusak, 0 duplikat, ID unik), tetapi rasa data tidak seimbang — 82,22% order berstatus Completed, dan sentimen negatif hanya 792 ulasan (0,7%). Konsistensi agregat justru terbukti persis: total net_sales $177.134.263,74 sama dengan nilai pada dataset_statistics.csv, demikian pula profit $76.146.395,76 dan average order value $1.282,50. Temuan ini menentukan pendekatan modeling: kelas timpang harus ditangani eksplisit, dan kolom yang dihitung dari seluruh histori (mis. customer_lifetime_value) tidak boleh menjadi fitur.

Makalah ini melaporkan akuisisi data, profil dan kualitas berbasis angka, serta penilaian kesiapterapan tiap modul. Hasilnya dipakai sebagai gerbang sebelum preprocessing dan training dimulai.

1.2 Rumusan Masalah

1. Data apa yang digunakan projek dan bagaimana cara akuisisinya?
2. Bagaimana profil dan kualitas data tersebut (keunikan, kelengkapan, validitas, konsistensi, ketepatan waktu, dan keseimbangan)?
3. Kolom mana yang layak dipakai untuk tiap modul machine learning, dan mana yang berisiko data leakage?
4. Apakah data siap dipakai untuk kelima modul, atau masih ada keterbatasan yang harus ditangani?
5. Bagaimana arsitektur alur data dari sumber hingga menjadi insight yang disajikan ke pemilik toko?

1.3 Tujuan

1. Menggambarkan sumber, jenis, dan struktur dataset yang dipakai projek.
2. Mendokumentasikan tahapan akuisisi berikut kendala dan penanganannya.
3. Mengukur profil dan kualitas data secara numerik dengan enam dimensi kualitas.
4. Menyusun matriks kesesuaian kolom terhadap kelima modul dan menandai kolom berisiko leakage.
5. Menilai kesiapterapan tiap modul dan merancang arsitektur alur data–model–aplikasi.

1.4 Manfaat

- Bagi pemilik toko: dasar bahwa insight yang muncul nanti dibangun dari data yang sudah diaudit, bukan asumsi.
- Bagi tim pengembang: gerbang kualitas sebelum training; daftar kolom yang boleh/tidak boleh dipakai; mitigasi eksplisit untuk kelas timpang.
- Bagi pembaca akademik: contoh audit data publik untuk kebutuhan machine learning, termasuk cara melaporkan keterbatasan secara jujur.

1.5 Ruang Lingkup

- Objek: lima berkas CSV E-commerce Sales & Customer Analytics (Kaggle) — ecommerce_sales_customer_analytics_150k.csv, order_items.csv, customer_master.csv, product_catalog.csv, dataset_statistics.csv.
- Periode data: 1 Januari 2021 sampai 31 Desember 2025 (1.826 tanggal unik).
- Aspek yang dibahas: akuisisi, profil, kualitas, kesiapterapan. Hasil pelatihan model tidak dibahas — model dilatih pada milestone berikutnya.
- Data tenant nyata tidak termasuk dalam makalah ini; pembahasan data tenant dibatasi pada peran arsitektural (isolasi per toko).
- Bahasa: Indonesia; nama kolom dan nilai data ditulis persis seperti pada dataset (Bahasa Inggris).

BAB II. DESKRIPSI DATA

2.1 Sumber Data

Sumber utama adalah dataset publik "E-Commerce Sales Analytics Dataset" (slug: datascikhan/e-commerce-sales-and-customer-analytics) di Kaggle, diunggah oleh akun datascikhan. Berkas diunduh manual melalui peramban pada 10 Oktober 2026 (cap waktu berkas 10/10/2026 20:53–20:54). Tidak ada kredensial atau API key yang dipakai; dataset bersifat publik dan dapat diakses tanpa login. Lampiran B memuat perintah untuk mengunduh ulang dan memverifikasi berkas.

Elemen	Keterangan
Sumber	Kaggle — datascikhan/e-commerce-sales-and-customer-analytics
Judul halaman	E-Commerce Sales Analytics Dataset (judul terverifikasi dari halaman dataset)
Cara akses	Unduh manual via peramban; tidak memakai API/scraper
Tanggal unduh	10 Oktober 2026
Format	5 berkas CSV, total ±88,6 MB (88.588.135 byte)
Lisensi/izin	Dataset publik Kaggle; dipakai untuk keperluan akademik projek
Isi	Transaksi e-commerce multi-komoditas lintas 7 negara (USA, UK, Germany, Canada, Australia, India, UAE), 2021–2025

Tabel 2.1 Sumber data dan cara akses

2.2 Jenis Data

Jenis	Contoh atribut	Keterangan
Temporal	order_date, order_time, Date Range	Format YYYY-MM-DD; 1.826 tanggal unik; dipakai forecasting dan RFM
Numerik kontinu	net_sales, gross_sales, profit, profit_margin_percentage	Nilai uang USD; dapat negatif pada profit (-1.281,59 s.d. 7.083,68)
Numerik diskrit	quantity, loyalty_points_earned, customer_order_count	quantity 1–24; customer_order_count 1–20
Kategorikal	order_status, customer_segment, customer_country, sales_channel	order_status: 4 nilai; segment: 4; country: 7 (USA 59,8%)

Jenis	Contoh atribut	Keterangan
Identitas (anonim)	order_id, customer_id, product_id	Format ORD-/CUST-/PROD- + angka; tidak memuat PII nyata
Teks bebas	customer_review, campaign_name	Ulasan singkat, median 5 kata; campaign 39,7% terisi
Geospasial (nominal)	customer_city, customer_state, region	15.516 kota, 38 state, 5 region; tidak ada koordinat

Tabel 2.2 Jenis data dan contoh atribut

2.3 Dataset yang Dihasilkan dan Relasinya

Dataset	Baris	Kolom	Satu baris mewakili
ecommerce_sales_customer_analytics_150k.csv	138.116	46	Satu transaksi (order) beserta pelanggan, nilai, dan hasil pengiriman/ulasan
order_items.csv	397.569	12	Satu baris item dalam sebuah order
customer_master.csv	25.000	11	Satu pelanggan (profil + biaya akuisisi)
product_catalog.csv	1.175	9	Satu produk (kategori, brand, harga)
dataset_statistics.csv	1	11	Ringkasan agregat seluruh dataset (bukan observasi)

Tabel 2.3 Dataset yang dihasilkan dan relasi

Relasi antarberkas memakai kunci: ecommerce_sales_customer_analytics_150k.csv.order_id → order_items.csv.order_id (satu order memiliki 1–18 item; rata-rata 2,88 item); ecommerce_sales_customer_analytics_150k.csv.customer_id → customer_master.csv.customer_id (24.911 dari 25.000 pelanggan master pernah bertransaksi; 89 tidak); order_items.csv.product_id → product_catalog.csv.product_id (seluruh 1.175 produk muncul di transaksi). dataset_statistics.csv tidak memiliki kunci dan hanya dipakai sebagai pembanding agregat.

2.4 Kamus Data

Kamus data mencantumkan seluruh kolom per berkas. Kolom yang tidak dipakai pada pemodelan diberi tanda “(tidak dipakai)”; kolom berisiko data leakage ditandai “(leakage)”. Detail persentase terisi tersedia di Lampiran A dan data/reports/data_dictionary.csv.

Kolom	Tipe	Keterangan
order_id	str	Kunci transaksi; unik 138.116; ORD-######
order_date	str (tanggal)	Tanggal order; 2021-01-01 s.d. 2025-12-31; 1.826 nilai unik
order_time	str	Jam order (HH:MM:SS); (tidak dipakai)
order_status	str	Completed 113.559 (82,22%), Returned 9.462 (6,85%), Cancelled 8.398 (6,08%), Pending 6.697 (4,85%)
sales_channel	str	Kanal penjualan (Marketplace/Website/Mobile App/Social Media); (tidak dipakai)
customer_id	str	Kunci pelanggan; CUST-######; 24.911 unik; kunci RFM dan churn
customer_name	str	Nama (sintetis); (tidak dipakai — identitas tidak diperlukan model)
customer_age	int64	Usia 18–74; fitur opsional segmentasi
gender	str	Female 66.439, Male 66.284, Non-Binary 5.393; opsional
customer_segment	str	Consumer 75.636, Premium 34.746, VIP 13.957, Business 13.777
customer_type	str	Loyal 129.447, Returning 8.335, New 334; opsional
customer_city / state / country / region	str	15.516 kota; 38 state; 7 negara; 5 region; country/region opsional
customer_postal_code	int64	Kode pos; (tidak dipakai)
payment_method / payment_status / currency	str	7 metode; 4 status; 7 mata uang; (tidak dipakai)
shipping_method / warehouse	str	4 metode; 19 gudang; (tidak dipakai)
delivery_days / estimated_delivery_days	float64	Terisi 113.559 (82,2%) — kosong persis pada order non-Completed
delivery_status	str	On Time/Delayed/Cancelled/Returned; opsional (anomali)
return_status / return_reason	str	Terisi 9.462 (6,85%) — hanya order Returned; 8 alasan
customer_rating	float64	Rating 1,6–5,0; terisi 82,2% (hanya Completed); rata-rata 3,68
review_sentiment	str	Positive 78.083 (68,76%), Neutral 34.684 (30,54%), Negative 792 (0,7%)
customer_review	str	Ulasan singkat; median 5 kata; (tidak dipakai — fitur teks kompleks)
marketing_channel / campaign_name	str	10 channel; campaign terisi 54.883 (39,74%); (tidak dipakai)
coupon_code	str	Terisi 27.614 (19,99%); (tidak dipakai)

Kolom	Tipe	Keterangan
loyalty_points_earned / redeemed	int64	Poin loyalitas; (tidak dipakai)
quantity	int64	Jumlah item per order, 1–24; dipakai anomaly (volume)
gross_sales / discount_amount / tax_amount / shipping_cost / product_cost	float64	Komponen nilai; (tidak dipakai — net_sales mewakili)
net_sales	float64	Nilai penjualan bersih per order; sum = $177.134.263,74; inti forecasting/RFM/anomaly
profit	float64	Profit per order; sum = $76.146.395,76; opsional
profit_margin_percentage	float64	-59,55 s.d. 77,59; (tidak dipakai)
customer_lifetime_value	float64	(leakage) dihitung dari seluruh histori; dilarang jadi fitur churn
is_repeat_customer	bool	(leakage) diturunkan dari histori lengkap
customer_order_count	int64	(leakage) diturunkan dari histori lengkap; rentang 1–20

Tabel 2.4 Kamus data ecommerce_sales_customer_analytics_150k.csv (46 kolom)

Kolom	Tipe	Keterangan
order_id	str	Kunci ke order; 138.116 unik; dipakai market basket
product_id	str	Kunci ke katalog; 1.175 unik; dipakai market basket
quantity	int64	1–5; opsional (Apriori biner tidak memakai bobot)
unit_price	float64	6,31–1.482,95; (tidak dipakai)
discount_percentage	float64	0–0,6; (tidak dipakai)
discount_amount	float64	(tidak dipakai)
gross_sales / tax_amount / shipping_cost / product_cost / profit	float64	(tidak dipakai)
net_sales	float64	Nilai item; opsional (bukan kebutuhan asosiasi)

Tabel 2.5 Kamus data order_items.csv (12 kolom)

Kolom	Tipe	Keterangan
customer_id	str	Kunci; 25.000 unik (CUST-000001 s.d. CUST-025000)
customer_name	str	Nama sintetis; (tidak dipakai)
customer_age	int64	18–74

Kolom	Tipe	Keterangan
gender	str	Female/Male/Non-Binary (3 nilai)
customer_segment	str	Consumer 13.638, Premium 6.301, VIP 2.542, Business 2.519 (di master)
customer_city / state / country / region	str	Geografi; country/region opsional
customer_postal_code	int64	516–99.950; (tidak dipakai)
customer_acquisition_cost	float64	5,01–79,99; opsional (fitur risiko churn, bukan label)

Tabel 2.6 Kamus data customer_master.csv (11 kolom)

Kolom	Tipe	Keterangan
product_id	str	Kunci; 1.175 unik (PROD-000001 s.d. PROD-001175)
product_name	str	Nama produk sintetis; (tidak dipakai)
product_category	str	15 kategori seimbang (68–91 produk); opsional (aturan per kategori)
product_subcategory	str	117 subkategori; (tidak dipakai)
brand	str	144 brand; (tidak dipakai)
supplier	str	10 supplier; (tidak dipakai)
unit_price	float64	6,31–1.482,95; (tidak dipakai — harga tidak dipakai Apriori)
product_cost	float64	(tidak dipakai)
product_rating	float64	2,5–4,9; (tidak dipakai)

Tabel 2.7 Kamus data product_catalog.csv (9 kolom)

Kolom	Tipe	Keterangan
Total Transactions	int64	138.116
Total Columns	int64	46
Total Customers	int64	24.911
Total Products Used	int64	138.116 (seluruh baris memakai produk)
Date Range	str	2021-01-01 to 2025-12-31
Total Revenue	str	$177.134.263,74 — cocok dengan SUM(net_sales)
Total Profit	str	$76.146.395,76 — cocok dengan SUM(profit)
Average Order Value	str	$1.282,50 — cocok dengan AVG(net_sales)

Kolom	Tipe	Keterangan
Average Rating	float64	3,68
Return Rate	str	6,85% — cocok dengan 9.462/138.116
Cancellation Rate	str	6,08% — cocok dengan 8.398/138.116

Tabel 2.8 Kamus data dataset_statistics.csv (ringkasan agregat; tidak dipakai training)

Seluruh agregat pada dataset_statistics.csv terbukti konsisten dengan perhitungan langsung dari berkas transaksi; berkas ini dipakai untuk memverifikasi integritas, bukan sebagai bahan training. Inkonsistensi kecil tidak ditemukan.

BAB III. AKUISISI DATA

3.1 Perangkat yang Digunakan

Perangkat	Fungsi
Peramban (browser) + Kaggle	Mengakses halaman dataset dan mengunduh 5 berkas CSV secara manual
Python 3.13 + pandas 2.3.3	Profiling otomatis (ml/src/profiling/profile_datasets.py), pemeriksaan null/duplikat/unik
Matplotlib	Pembuatan grafik profiling dan grafik makalah
Script khusus projek	ml/src/profiling/column_suitability.py — matriks kecocokan kolom × model
Laporan profiling	data/reports/profiling.md, data_dictionary.csv, column_suitability.md (hasil sebelum makalah ditulis)

Tabel 3.1 Perangkat yang digunakan dalam akuisisi

3.2 Tahapan Akuisisi

Akuisisi dilakukan dalam dua tahap. Tahap 1 adalah pengambilan berkas dari Kaggle dan verifikasi integritas. Tahap 2 adalah profiling dan pemeriksaan kecocokan terhadap rencana pemodelan. Pemisahan tahap ini membuat kesalahan sumber (berkas salah/rusak) ketahuan sebelum analisis berjalan.

Gambar 3.1 Corong akuisisi data

3.2.1 Tahap 1 — Pengambilan dan Verifikasi Berkas

Kelima berkas diunduh manual pada 10 Oktober 2026 ke folder data/raw/. Berkas terbesar adalah ecommerce_sales_customer_analytics_150k.csv (48,7 MB), diikuti order_items.csv (37,5 MB); total ±88,6 MB. Tidak ada proses scraping: data memang disediakan sebagai berkas unduhan oleh pengunggah di Kaggle.

Verifikasi dilakukan dengan membaca setiap berkas memakai pandas dengan encoding UTF-8 dan encoding_errors="replace". Hasilnya: seluruh berkas terbaca, 0 karakter rusak (U+FFFD) ditemukan pada pemeriksaan isi, dan 0 baris duplikat penuh. Kolom yang

diduga sensitif (nama, kota) tetap disimpan apa adanya karena bersifat publik, namun tidak ditampilkan di makalah.

3.2.2 Tahap 2 — Profiling dan Gerbang Kesesuaian

Profiling otomatis menghasilkan data/reports/profiling.md dan data_dictionary.csv (46 + 12 + 11 + 9 + 11 = 89 kolom). Hasil utama: tidak ada null pada kolom inti; kolom pasca-transaksi (delivery_days, customer_rating, review_sentiment, customer_review) terisi 113.559 (82,2%) dan kosong pada order non-Completed; campaign_name terisi 54.883 (39,74%); coupon_code 27.614 (19,99%); return_status/return_reason 9.462 (6,85%).

Tahap ini ditutup dengan matriks kecocokan kolom × model (data/reports/column_suitability.md). Tiga kolom ditandai berisiko data leakage dan dilarang menjadi fitur: customer_lifetime_value, customer_order_count, is_repeat_customer (ketiganya dihitung dari seluruh histori, termasuk informasi masa depan relatif terhadap label churn). File dataset_statistics.csv dinyatakan tidak dipakai sebagai bahan training.

3.3 Kendala dan Penanganan

Kendala	Dampak	Penanganan
Encoding campuran (sel ‘Baden-Württemberg’ tampil rusak di laporan profiling)	Sebagian karakter non-ASCII hilang/berubah pada tampilan laporan	Membaca berkas dengan encoding_errors="replace"; pemeriksaan isi menunjukkan 0 karakter rusak; nilai dicatat apa adanya, tidak dinormalkan manual
24.557 order (17,78%) tidak punya rating/ulasan	Model berbasis sentimen/rating tidak bisa dilatih dari seluruh data	Filter order_status = Completed untuk tugas berbasis rating; analisis lain tetap memakai semua baris
Sparsity customer × product 98,65% (394.787 pasangan unik dari 24.911 × 1.175)	Collaborative filtering tidak layak	Market basket dihitung per transaksi (order_items), bukan matriks pengguna–item
Sentimen sangat timpang (Negative 792; 0,7%)	Model klasifikasi bias ke kelas mayoritas	F1-macro / PR-AUC; class weighting; atau anotasi manual untuk subset negatif
Kupon & campaign jarang diisi (19,99% / 39,74%)	Fitur marketing lemah bila dipakai	Ditandai opsional; tidak dipakai pada model inti
524 pelanggan hanya bertransaksi 1 kali	Label churn ambigu (baru vs kabur)	Dikecualikan dari label churn; diprediksi terpisah sebagai “pelanggan baru”

Tabel 3.2 Kendala akuisisi dan penanganannya

3.4 Etika dan Keamanan Data

Dataset bersifat publik dan diunduh manual; tidak ada bypass akses, scraping terselubung, atau pelanggaran ketentuan layanan. Data memuat nama pelanggan, tetapi nama tersebut sintetis — tidak merujuk individu nyata — dan tidak ditampilkan di makalah ini. Penggunaan dibatasi untuk kepentingan akademik projek; data tidak didistribusikan ulang. Kepatuhan terhadap UU No. 27 Tahun 2022 tentang Pelindungan Data Pribadi (UU PDP) tetap relevan sebagai prinsip: minimisasi data, tujuan jelas, dan larangan menautkan ke identitas asli. Berkas mentah disimpan lokal (data/raw/, tidak di-commit ke Git) dan hanya dipakai untuk profiling serta pelatihan model global.

3.5 Reprodusibilitas

Lingkungan: Windows, Python 3.13, pandas 2.3.3, matplotlib; Node 26 untuk dokumen; tanggal unduh 10 Oktober 2026; periode data 2021-01-01 s.d. 2025-12-31. Perintah profiling dan grafik tercantum pada Lampiran B. Berkas hasil (profiling.md, data_dictionary.csv, column_suitability.md) tersimpan di data/reports/ dan menjadi sumber angka pada BAB II–V.

BAB IV. PROFIL DAN KUALITAS DATA

Profil di bawah dihitung dari berkas mentah pada data/raw/ dengan script ml/src/profiling/profile_datasets.py dan pandas. Angka yang disebut adalah hasil perhitungan langsung, bukan perkiraan. Dataset akhir yang dipakai pemodelan adalah ecommerce_sales_customer_analytics_150k.csv (138.116 transaksi); jumlah ini lebih kecil dari master pelanggan (25.000) karena 89 pelanggan di customer_master.csv tidak pernah bertransaksi, dan 24.911 di antaranya tercatat di transaksi.

4.1 Ringkasan Statistik

Ukuran	Nilai
Jumlah transaksi (order)	138.116
Pelanggan unik (transaksi)	24.911 (dari 25.000 di master; 89 tidak bertransaksi)
Produk unik	1.175 (seluruhnya muncul di transaksi)
Baris order_items	397.569 (rata-rata 2,88 item/order; maksimum 18)
Periode data	1 Januari 2021 – 31 Desember 2025; 1.826 tanggal unik (seluruh hari terisi)
Total net_sales	$177.134.263,74 (persis sama dengan dataset_statistics.csv)
Total profit	$76.146.395,76 (persis sama dengan dataset_statistics.csv)
Average order value	$1.282,50 (persis sama dengan dataset_statistics.csv)
Rating rata-rata	3,68 (n = 113.559; rentang 1,6–5,0)
Order dengan rating/ulasan	113.559 (82,2%); sisanya 24.557 (17,78%) non-Completed
Return rate / Cancellation rate	6,85% / 6,08% (persis sama dengan dataset_statistics.csv)
Kuantitas per order	rata-rata 2,88; rentang 1–24

Tabel 4.1 Ringkasan statistik utama

Konsistensi internal berkas sangat baik: seluruh agregat pada dataset_statistics.csv cocok persis dengan perhitungan dari baris mentah. Ini berarti berkas transaksi tidak korup dan tidak mengalami pengurangan/penambahan baris sejak dataset dirilis. Selisih 89 pelanggan master tanpa transaksi wajar secara bisnis (profil terdaftar, belum pernah membeli).

4.2 Sebaran Transaksi dan Negara

Gambar 4.1 Sebaran transaksi per negara

USA mendominasi dengan 82.600 transaksi (59,8%), diikuti UK 20.235 (14,7%), Germany 11.593 (8,4%), Canada 7.015 (5,1%), Australia 6.794 (4,9%), India 5.707 (4,1%), dan UAE 4.172 (3,0%). Ketidakseimbangan geografis tajam: 74,5% transaksi berasal dari dua negara berbahasa Inggris. Implikasi: model yang belajar pola lintas negara akan sangat bias ke USA; untuk kebutuhan projek, negara dipakai sebagai fitur opsional, bukan pembatas populasi, dan evaluasi perlu dibaca dengan kesadaran dominasi USA.

Distribusi segmen pelanggan pada transaksi: Consumer 75.636 (54,7%), Premium 34.746 (25,2%), VIP 13.957 (10,1%), Business 13.777 (10,0%). Sebaran region: South 43.990, sisanya menyebar ke East, West, Central, dan North (North terkecil, 16.624). Keempat segmen sama-sama memiliki cukup sampel untuk analisis RFM.

4.3 Karakteristik Status Order dan Produk

Gambar 4.2 Komposisi status order

Komposisi order_status: Completed 113.559 (82,22%), Returned 9.462 (6,85%), Cancelled 8.398 (6,08%), Pending 6.697 (4,85%). Pola ini penting: seluruh kolom pasca-transaksi (delivery_days, estimated_delivery_days, customer_rating, review_sentiment, customer_review) kosong persis pada 24.557 order non-Completed — bukan hilang acak. Kolom-kolom itu terisi 82,2% karena desain data, bukan cacat pengumpulan.

Gambar 4.3 Sebaran kategori produk

Katalog 1.175 produk terbagi ke 15 kategori yang seimbang (68–91 produk per kategori; Sports & Outdoors 91 terbanyak, Fashion 68 paling sedikit) dan 117 subkategori. Keseimbangan kategori berarti tidak perlu tindakan penyeimbangan untuk analisis tingkat kategori. order_items memuat 397.569 baris dengan rata-rata 2,88 item per order dan maksimum 18; seluruh 1.175 produk muncul pada transaksi. Ditemukan 87 pasangan

ganda (order_id, product_id) pada order_items — kemungkinan entri duplikat yang harus dideduplicasi sebelum market basket analysis.

4.4 Distribusi Rating dan Sentimen

Gambar 4.4 Distribusi rating pelanggan

Rating mengumpul di kisaran 3,3–3,9 dengan puncak 3,7 (9.362 ulasan, 8,2% dari yang ber-rating) dan rata-rata 3,68. Ekor bawah tipis: rating di bawah 2,5 jarang muncul. Pola ini wajar untuk e-commerce, tetapi berarti model klasifikasi berbasis rating akan hidup dengan kelas mayoritas; jangan menafsirkan akurasi tinggi sebagai keberhasilan — gunakan metrik seimbang.

Gambar 4.5 Komposisi sentimen ulasan

Sentimen: Positive 78.083 (68,76%), Neutral 34.684 (30,54%), Negative 792 (0,7%). Kelas negatif adalah minoritas ekstrem — rasio hampir 1 : 100 : 99 terhadap Neutral. Konsekuensi langsung: model klasifikasi sentimen tanpa penanganan imbalance akan mengabaikan Negative sepenuhnya. Strategi wajib: F1-macro atau PR-AUC, class weighting, atau oversampling (SMOTE) dan evaluasi pada test set berstratifikasi.

4.5 Distribusi Temporal

Gambar 4.6 Jumlah transaksi per bulan (2021–2025)

Seluruh 1.826 tanggal dalam rentang 2021-01-01 s.d. 2025-12-31 terisi — tidak ada hari kosong. Volume bulanan stabil di kisaran ±1.600–2.500 transaksi dengan puncak yang berulang setiap November–Desember (musim liburan/akhir tahun, ditandai batang gelap pada grafik). Tren jangka panjang datar tanpa structural break. Implikasi untuk forecasting: komponen seasonality tahunan tersedia dan perlu dieksplisitkan (mis. model additive seasonal atau fitur bulan); data cukup untuk split train/validasi berbasis waktu.

4.6 Kelengkapan Atribut

Gambar 4.7 Keterisian atribut pasca-transaksi dan marketing

Kolom inti (order_id, order_date, customer_id, quantity, net_sales, profit) terisi 100%. Kolom pasca-transaksi (delivery_days, estimated_delivery_days, customer_rating, review_sentiment, customer_review) terisi 82,2% — kosong persis pada order non-Completed. Kolom retur (return_status, return_reason) hanya terisi 9.462 (6,85%) — hanya untuk order Returned; return_reason tertinggi null 93,15%. Kolom marketing opsional: campaign_name 39,74% terisi, coupon_code 19,99%. Untuk pemodelan, kolom-kolom ini ditandai opsional dan tidak boleh menjadi fitur wajib.

4.7 Pemeriksaan Kualitas Data

Dimensi	Hasil pemeriksaan	Status
Keunikan	0 duplikat baris penuh pada kelima berkas; 0 duplikat order_id (138.116 unik); 0 duplikat customer_id di master (25.000); 87 pasangan ganda (order_id, product_id) di order_items → deduplicasi sebelum Apriori	Baik (dengan catatan 87 pasang)
Kelengkapan	Kolom inti 100%; pasca-transaksi 82,2% (Order non-Completed); campaign 39,74%; coupon 19,99%; return 6,85%	Cukup
Validitas	Rating dalam 1,6–5,0; tanggal ISO 8601 valid dan kontinyu 1.826 hari; quantity 1–24; harga positif; 0 karakter rusak (U+FFFD)	Baik
Konsistensi	Agregat net_sales, profit, AOV, return 6,85%, cancellation 6,08% persis sama dengan dataset_statistics.csv; seluruh 1.175 produk muncul di transaksi; 24.911 dari 25.000 pelanggan master bertransaksi	Baik
Ketepatan waktu	Rentang penuh 2021-01-01 s.d. 2025-12-31; 1.826 tanggal unik = seluruh hari terisi; timeliness layak untuk analisis tren	Baik
Keseimbangan	Sentimen Negative 0,7% (792); order_status didominasi Completed (82,2%); negara didominasi USA (59,8%)	Perlu penanganan

Tabel 4.2 Matriks kualitas data (enam dimensi)

Kesimpulan kualitas: data layak dipakai dengan catatan — (1) kelas Negative dan order non-Completed perlu penanganan eksplisit; (2) 87 pasangan ganda order_items harus dideduplicasi; (3) kolom marketing opsional jangan dijadikan fitur wajib; (4) analisis lintas negara perlu kesadaran bias USA. Tidak ditemukan cacat struktural yang membatalkan pemakaian data.

BAB V. KESIAPTERAPAN DATA PADA PROJEK

Bab ini menjembatani data dengan projek. Isinya rencana dan penilaian kelayakan berbasis angka pada BAB IV — bukan hasil pelatihan model. Kelima modul di bawah adalah modul yang disepakati pada desain projek (lihat docs/superpowers/specs/2026-10-31-toko-analitik-ai-design.md).

5.1 Arsitektur Sistem (Rencana)

Gambar 5.1 Arsitektur data–model–aplikasi (rencana)

Alur data dirancang dua jalur. Jalur pelatihan (selesai sampai profiling): berkas Kaggle → data/raw/ → profiling dan matriks kecocokan. Jalur layanan (rencana): pemilik toko memasukkan transaksi lewat impor CSV, formulir, atau chatbot (dengan konfirmasi) ke MySQL toko_analitik_ai per tenant; FastAPI (port 8001) memuat artefak model global yang dilatih dari dataset 150k dan melayani prediksi per toko; Next.js menampilkan dashboard dan chatbot. Pemisahan ini penting: dataset publik dipakai hanya untuk melatih artefak global; data tenant tidak pernah dipakai melatih ulang tanpa alur validasi eksplisit, dan tenant A tidak pernah melihat data tenant B (isolasi lewat kunci X-Tenant-Id).

Model global versi pertama dilatih dari dataset publik; setelah tenant nyata menumpuk data tervalidasi, evaluasi ulang dilakukan sebelum mempertimbangkan personalisasi per tenant. Keputusan ini konservatif dan sesuai UU PDP: tujuan pemrosesan jelas, data diminimalkan, dan akses dibatasi.

5.2 Pemetaan Data ke Tahap Pemodelan

Tahap / modul	Data yang dipakai	Jumlah tersedia	Kesiapan
Forecasting penjualan	order_date (agregasi harian), net_sales	1.826 hari kontinyu (2021–2025); 138.116 transaksi	Siap
RFM + K-Means	customer_id, order_date, net_sales	24.911 pelanggan; frekuensi rata-rata ≈ 5,5 transaksi	Siap
Market basket (Apriori)	order_id, product_id dari order_items (dedupe 87 pasangan ganda)	138.116 order; 397.569 baris item; 1.175 produk	Siap dengan catatan

Tahap / modul	Data yang dipakai	Jumlah tersedia	Kesiapan
Churn (365 hari sebelum 2025-12-31)	customer_id + fitur jendela 365 hari (frekuensi, moneter, recency, acquisition_cost opsional)	24.911 pelanggan: 8.156 churn (32,8%) / 16.755 aktif (67,2%); 524 single-transaction (404 di antaranya churn) — opsional dikecualikan → 7.752 / 16.635	Siap dengan catatan
Anomaly detection	order_date, net_sales, quantity (deret/indikator per bulan)	138.116 transaksi; 60 titik bulanan	Siap
Collaborative filtering (ditolak)	Matriks user × item	Sparsity 98,65% (394.787 pasangan unik dari 24.911 × 1.175)	Tidak layak — ditolak

Tabel 5.1 Pemetaan data ke tahap pemodelan

Pendekatan yang ditolak: collaborative filtering berbasis matriks pengguna–produk. Sparsity 98,65% membuat kemiripan pengguna tidak terukur; Apriori per transaksi jauh lebih tepat karena struktur data memang relasional (order → item), bukan klik/rating matrix.

5.3 Forecasting Penjualan (Modul 1)

Label/ground truth: tidak ada — ini masalah deret waktu. Target: net_sales harian/bulanan. Pembagian data wajib berbasis waktu (train 2021–2024, validasi 2025, atau rolling-origin cross-validation), bukan acak. Pendekatan layak: (1) naïve + moving average sebagai baseline; (2) Prophet atau ARIMA/SARIMA untuk seasonality tahunan (puncak Nov–Des terbukti pada Gambar 4.6); (3) regresi dengan fitur kalender bila dibutuhkan. Metrik: MAE, RMSE, MAPE; laporkan juga MASE agar sebanding dengan naïve. Data 1.826 titik harian cukup; agregasi bulanan (60 titik) hanya untuk eksplorasi, terlalu sedikit untuk training model kompleks.

Kesiapan: Siap. Risiko utama bukan data, melainkan salah memilih horizon dan evaluasi — horizon 1–3 bulan realistis untuk keputusan stok UMKM.

5.4 RFM + K-Means (Modul 2)

Label: tidak ada (unsupervised). Fitur: Recency (hari sejak order terakhir terhadap 2025-12-31), Frequency (jumlah order per pelanggan, 1–20), Monetary (sum net_sales per pelanggan). Standardisasi wajib (StandardScaler) karena skala berbeda jauh. Pemilihan

k: elbow dan silhouette pada rentang 3–8; pilih k terendah dengan silhouette stabil. Output: label segmen per pelanggan + profil median R/F/M + usulan aksi bisnis (mis. win-back untuk high-F low-R). Evaluasi: silhouette, stabilitas antar-seed, dan keterbacaan segmen oleh pemilik toko.

Kesiapan: Siap. Catatan: frequency sangat timpang (mayoritas rendah), jadi pertimbangkan transformasi log pada Frequency dan Monetary sebelum clustering; anomali ekstrim (whale customer) dapat dipotong pada persentil 99 atau diberi label terpisah.

5.5 Market Basket Analysis (Modul 3)

Ground truth: tidak ada; hasil berupa aturan asosiasi. Input: setiap order sebagai transaksi itemset dari order_items setelah deduplicasi 87 pasangan (order_id, product_id). Apriori dengan min_support 1% (≈1.381 order) dan min_confidence 50%; metrik utama lift (aturan dengan lift > 1 menarik). Jangan gunakan matriks pengguna–item (sparsity 98,65%). Filter aturan yang hanya mengulang best-seller; utamakan aturan lintas kategori untuk peluang bundling.

Kesiapan: Siap dengan catatan — (1) dedupe wajib; (2) aturan dari order non-Completed sebaiknya dikeluarkan (pesanan dibatalkan/dikembalikan bukan preferensi pembelian); (3) jumlah aturan bisa besar — laporkan top-N terkurasi, bukan seluruh aturan.

5.6 Prediksi Churn (Modul 4)

Definisi label (dari desain projek): pelanggan disebut churn bila tidak ada pembelian dalam 365 hari sebelum 2025-12-31. Hasil label pada 24.911 pelanggan: 8.156 churn (32,8%) dan 16.755 aktif (67,2%). Sebanyak 524 pelanggan dengan tepat satu transaksi ambigu (404 tergolong churn, 120 aktif); dua perlakuan sah — (a) training pada seluruh 24.911 dengan single-transaction ditandai, atau (b) keluarkan 524 tersebut sehingga tersisa 24.387 berlabel (7.752 churn / 16.635 aktif). Dipilih opsi (b) untuk label bersih; kelompok itu dilaporkan terpisah sebagai “pelanggan baru”.

Fitur (jendela 365 hari sebelum referensi, bukan seluruh histori): recency, frequency, monetary, rata-rata nilai order, jumlah kategori berbeda, acquisition_cost (opsional). Kolom customer_lifetime_value, customer_order_count, dan is_repeat_customer

DILARANG masuk fitur — ketiganya dihitung dari seluruh histori dan memuat informasi "masa depan" terhadap label. Pembagian data: stratified train/test 80/20 atau stratified k-fold (k=5). Model: Logistic Regression (baseline, interpretabilitas) dan Random Forest (non-linear). Metrik: Precision, Recall, F1, dan PR-AUC — bukan accuracy, karena kelas tidak seimbang dan biaya salah klasifikasi asimetris (kehilangan pelanggan aktif lebih mahal daripada mengejar yang sudah churn).

Kesiapan: Siap dengan catatan — (1) label sah hanya untuk jendela 365 hari; jangan ubah referensi tanggal tanpa menghitung ulang label; (2) 524 pelanggan single-transaction dikeluarkan dari training; (3) validasi bahwa tidak ada fitur bocor dari periode label.

5.7 Deteksi Anomali (Modul 5)

Ground truth: tidak ada (unsupervised). Dua lapis: (1) statistik per bulan — z-score atau IQR pada net_sales dan quantity; (2) Isolation Forest (contamination ±0,5%) pada fitur net_sales, quantity, dan deviasi harga terhadap normal. Output: skor anomali per order dan daftar tinjauan untuk pemilik toko (bukan blokir otomatis — keputusan tetap manusia). Estimasi: ±690 order dari 138.116 akan ter-flag pada kontaminasi 0,5%; jumlah pasti menunggu training.

Kesiapan: Siap. Catatan: anotasi manual pada sampel ter-flag tetap dibutuhkan untuk membedakan penipuan, salah input, atau lonjakan wajar (promo).

5.8 Mitigasi Keterbatasan Data

Keterbatasan	Dampak pada model	Mitigasi
Sentimen Negative 0,7% (792)	Klasifikasi sentimen mengabaikan kelas minoritas	F1-macro/PR-AUC; class weighting; oversampling; anotasi manual 500–1.000 sampel negatif bila sentimen dipakai
Order non-Completed 17,78% (24.557)	Rating/review kosong; bias ke pembelian sukses	Filter Completed untuk tugas berbasis rating/sentimen; analisis lain pakai semua baris
Dominasi USA 59,8%	Model bias pola USA	Negara sebagai fitur, bukan filter; laporan evaluasi per negara; generalisasi ke tenant Indonesia perlu validasi ulang
Sparsity user×item 98,65%	Collaborative filtering gagal	Apriori per transaksi; evaluasi aturan via lift
87 pasangan ganda order_items	Aturan asosiasi melebih-hitung item	Dedupe (order_id, product_id) sebelum Apriori; catat jumlahnya di laporan

Keterbatasan	Dampak pada model	Mitigasi
Data leakage (CLV, order_count, is_repeat)	Churn accuracy palsu	Daftar hitam fitur di ml/; review fitur sebelum training; audit di code review
524 pelanggan single-transaction	Label churn ambigu	Keluarkan dari training; laporkan terpisah
campaign 39,74% / coupon 19,99% terisi	Fitur marketing lemah/bias	Opsional saja; jangan wajib; imputasi atau drop
Dataset sintetis multi-negara	Pola belum tentu berlaku untuk tenant Indonesia	Model global hanya baseline; kalibrasi ulang dengan data tenant saat tersedia; jangan klaim performa untuk toko nyata

Tabel 5.2 Mitigasi keterbatasan data

5.9 Rencana Tahap Selanjutnya

1. Pra-pemrosesan: deduplikasi order_items; filter Completed untuk tugas rating/sentimen; standardisasi RFM; agregasi harian net_sales.
2. EDA lanjutan: cek seasonality (dekomposisi), korelasi fitur churn, dan stabilitas segmen dari waktu ke waktu.
3. Pelatihan modul 1–5 dengan pembagian data yang disebut di 5.3–5.7; simpan artefak ke /artifacts/global/<model>/<versi>/.
4. Evaluasi: MAE/RMSE/MAPE (forecasting), silhouette (K-Means), lift/confidence (Apriori), PR-AUC (churn), manual review sampel anomali.
5. Integrasi: FastAPI menyimpan artefak; NestJS memanggil endpoint prediksi; hasil disajikan di dashboard Next.js dan lewat chatbot dengan konfirmasi tindakan.
6. Pemantauan: log prediksi; hitung ulang statistik kualitas bulanan (duplikat baru, null rate, drift); retrain per 3 bulan atau saat drift terdeteksi.

BAB VI. PENUTUP

6.1 Kesimpulan

1. Data yang digunakan projek adalah dataset publik E-Commerce Sales Analytics (Kaggle, datascikhan), diunduh manual 10 Oktober 2026: lima berkas CSV, 46 kolom inti, 138.116 transaksi, 24.911 pelanggan unik, 1.175 produk, periode 2021–2025.
2. Akuisisi dua tahap (pengambilan + verifikasi, lalu profiling) berhasil: 0 karakter rusak, 0 duplikat baris penuh, 0 duplikat order_id, seluruh 1.826 tanggal terisi, dan agregat net_sales/profit/AOV/return/cancellation persis sama dengan dataset_statistics.csv.
3. Kualitas enam dimensi: keunikan, validitas, konsistensi, ketepatan waktu = Baik; kelengkapan = Cukup (inti 100%, pasca-transaksi 82,2%, marketing 19,99–39,74%); keseimbangan = Perlu penanganan (Sentimen Negative 0,7%; Completed 82,2%; USA 59,8%).
4. Tiga kolom berisiko data leakage (customer_lifetime_value, customer_order_count, is_repeat_customer) dilarang menjadi fitur; collaborative filtering ditolak karena sparsity 98,65%.
5. Kesiapterapan kelima modul: Forecasting (Siap), RFM + K-Means (Siap), Market Basket (Siap dengan catatan — dedupe 87 pasangan, filter Completed), Churn (Siap dengan catatan — label 8.156/16.755, 524 single-transaction dikecualikan), Anomaly Detection (Siap). Pelatihan model adalah tahap berikutnya, belum termasuk makalah ini.
6. Arsitektur direncanakan: Kaggle/150k → profiling → artefak global FastAPI → MySQL tenant (per toko, isolasi X-Tenant-Id) → Next.js + chatbot; data tenant tidak dipakai melatih ulang tanpa validasi.

6.2 Saran

1. Tangani imbalance eksplisit: F1-macro/PR-AUC, class weighting, dan anotasi manual 500–1.000 sampel ulasan Negative sebelum model sentimen dipakai.
2. Dedup order_items (87 pasangan order_id–product_id) dan filter order non-Completed untuk analisis rating/sentimen/asosiasi.

3. Sensitivity analysis jendela churn (180/270/365 hari) dan laporkan jumlah label tiap varian.
4. Kalibrasi ulang seluruh model dengan data tenant Indonesia saat tersedia; jangan klaim performa dataset sintetis untuk toko nyata.
5. Pemantauan kualitas bulanan (duplikat baru, drift, null rate) dan retrain per 3 bulan atau saat drift terdeteksi.
6. Perkaya data dengan sumber tenant (impor CSV/form chatbot) dan tetapkan tata kelola: enkripsi at rest, kontrol akses per peran, dan retensi sesuai UU PDP.

DAFTAR PUSTAKA

[1] R. Agrawal and R. Srikant, “Fast algorithms for mining association rules,” in Proc. 20th Int. Conf. Very Large Data Bases (VLDB), Santiago, Chile, Sep. 1994, pp. 487–499.

[2] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, and R. Wirth, “CRISP-DM 1.0: Step-by-step data mining guide,” NCR Systems Engineering Copenhagen, 2000.

[3] C. Shearer, “The CRISP-DM model: The new blueprint for data mining,” Journal of Data Warehousing, vol. 5, no. 4, pp. 13–22, 2000.

[4] Y. Wand and R. Y. Wang, “Anchoring data quality dimensions in ontological foundations,” Communications of the ACM, vol. 39, no. 11, pp. 86–95, 1996.

[5] ISO 8000-1:2022, Data quality — Part 1: Overview, Geneva, Switzerland: International Organization for Standardization, 2022.

[6] J. MacQueen, “Some methods for classification and analysis of multivariate observations,” in Proc. 5th Berkeley Symp. Math. Statistics and Probability, vol. 1, Berkeley, CA, USA, 1967, pp. 281–297.

[7] L. Breiman, “Random forests,” Machine Learning, vol. 45, no. 1, pp. 5–32, 2001.

[8] T. Hastie, R. Tibshirani, and J. Friedman, The Elements of Statistical Learning: Data Mining, Inference, and Prediction, 2nd ed. New York, NY, USA: Springer, 2009.

[9] J. Han, J. Pei, and M. Kamber, Data Mining: Concepts and Techniques, 3rd ed. Waltham, MA, USA: Morgan Kaufmann, 2011.

[10] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.

[11] Republik Indonesia, Undang-Undang Republik Indonesia Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi, Lembaran Negara RI Tahun 2022 No. 196, 2022.

[12] datascikhan, “E-Commerce Sales Analytics Dataset,” Kaggle. Tersedia: https://www.kaggle.com/datasets/datascikhan/e-commerce-sales-and-customer-analytics (diakses 10 Oktober 2026).

LAMPIRAN A. Statistik Deskriptif Per Kolom

Ringkasan per kolom kunci. “Terisi %” = proporsi non-null; “Unik” = jumlah nilai berbeda; peran: id / atribut / nilai_uang / tanggal. Sumber: ml/src/profiling/profile_datasets.py; rincian lengkap di data/reports/data_dictionary.csv dan profiling.md.

Kolom	Tipe	Terisi %	Unik	Peran
order_id	str	100	138.116	id
order_date	str	100	1.826	tanggal
customer_id	str	100	24.911	id
customer_segment	str	100	4	atribut
customer_country	str	100	7	atribut
region	str	100	5	atribut
payment_method	str	100	7	atribut
order_status	str	100	4	atribut
delivery_days	float64	82,2	15	atribut
customer_rating	float64	82,2	35	nilai_uang (skor)
review_sentiment	str	82,2	3	atribut
return_reason	str	6,85	8	atribut
campaign_name	str	39,74	17	atribut
coupon_code	str	19,99	40	atribut
quantity	int64	100	24	kuantitas
net_sales	float64	100	115.457	nilai_uang
profit	float64	100	96.545	nilai_uang
profit_margin_percentage	float64	100	7.947	nilai_uang
customer_lifetime_value	float64	100	24.769	nilai_uang (leakage)
customer_order_count	int64	100	19	atribut (leakage)
is_repeat_customer	bool	100	2	atribut (leakage)

customer_master.csv (25.000 × 11): customer_id unik penuh (25.000), customer_age 18–74, gender 3 nilai, customer_segment 4 nilai (Consumer 13.638 / Premium 6.301 / VIP

2.542 / Business 2.519 di master), customer_acquisition_cost $5,01–$79,99; 0 null. 89 pelanggan tanpa transaksi.

order_items.csv (397.569 × 12): order_id 138.116 unik; product_id 1.175 unik; quantity 1–5 (≤5 unik); net_sales, profit per item; 87 pasangan (order_id, product_id) ganda → dedupe sebelum Apriori.

product_catalog.csv (1.175 × 9): product_id unik penuh; 15 kategori seimbang (68–91); 117 subkategori; 144 brand; 10 supplier; unit_price $6,31–$1.482,95; product_rating 2,5–4,9.

dataset_statistics.csv (1 × 11): agregat yang terverifikasi persis cocok dengan perhitungan baris mentah (net_sales $177.134.263,74; profit $76.146.395,76; AOV $1.282,50; return 6,85%; cancellation 6,08%; rating 3,68). Dipakai sebagai pemeriksaan integritas, bukan bahan training.

LAMPIRAN B. Perintah Reprodusibilitas

Lingkungan: Windows; Python 3.13; pandas 2.3.3; matplotlib; Node.js 26; tanggal unduh dataset 10 Oktober 2026.

Mengunduh ulang: buka https://www.kaggle.com/datasets/datascikhan/e-commerce-sales-and-customer-analytics → Download (perlu login Kaggle) → ekstrak lima CSV ke data/raw/.

Profiling:

python ml/src/profiling/profile_datasets.py

Matriks kecocokan kolom × model:

python ml/src/profiling/column_suitability.py

Grafik makalah (matplotlib, backend Agg):

python docs/makalah/assets/charts.py

Hasil tertulis: data/reports/profiling.md, data/reports/data_dictionary.csv, data/reports/column_suitability.md/.csv. Dokumen Word ini dibangun dengan: node docs/makalah/gen_makalah.js (modul docx 9.15.2).

Berkas mentah tidak di-commit ke Git (lihat .gitignore); makalah dapat diverifikasi ulang dari berkas yang sama di data/raw/.